


DCA- 0131: Ciência de Dados

Análise Exploratória de Dados - EDA

Luiz Affonso Guedes - affonso@dca.ufrn.br



Ementa

- Introdução à Ciência de Dados
 - Conceitos fundamentais, importância, aplicações e ciclo de vida de dados.
- Tratamentos de dados
 - Captura, limpeza, filtrações, imputação e armazenamento de dados.
 - Pacote Pandas do Python
- Análise Exploratória de Dados
 - Conceitos de estatísticas e visualização de dados.
 - Pacotes Scipy e Seaborn do Python
- Processamento de Dados
 - Técnicas de regressão e classificação de dados.
 - Pacote Scikit-learn do Python
- Interpretação de Dados
 - Explainable AI (XAI)
 - Pacotes Shap e XAI do Python

Data Science

“Ciência de Dados é a prática de transformar **dados** brutos em insights de **negócio** utilizando **métodos científicos**.”



Desafios: Visualização

Como apresentar os dados de forma a obter informação útil?



Visualização de Dados




John Snow, médico higienista inglês, considerado um dos pais da epidemiologia¹, ficou conhecido pela solução dada a um surto de cólera no bairro do Soho, na Inglaterra, baseando-se nos princípios básicos na análise espacial.

Visualização de Dados



DENSIDADE DEMOGRÁFICA E ILHAS DE CALOR

Município de São Paulo, com variação de temperatura de 24 °C a 32 °C, em 3/9/1999




Fonte: Atlas Ambiental do Município de São Paulo

Visualização de Dados



Ciclo de Atividades de Ciência de Dados



Pipeline de Dados

Parte 1 Planejamento

Parte 2 Preparação dos dados

Parte 3 Modelagem

Parte 4 Acompanhamento

Pipeline de Ciência de Dados

Análise de Negócio

Toda análise precisa de um **objetivo bem definido e uma métrica**. A análise deve ser realizada em **conjunto com a área de negócio** para evitar a perda de foco do analista e facilitar a geração de insights.

Coleta de Dados

A **fonte de dados pode ser diversas**, desde redes sociais, bancos relacionais, csv.. etc. É importante que todos os dados necessários para a análise estejam disponíveis.


Análise dos Dados

Métodos estatísticos e de inteligência artificial são utilizados para extração de padrões. Geralmente é necessário combinar múltiplas fontes de dados e transformar variáveis para extração de padrões.

Avaliação e Implantação do Insight

Uma análise deve servir de base para a mudança de processos que geralmente visam retorno financeiro. É **necessário validar se as decisões tomadas surtem efeitos reais, abrindo portas para outras análises.**

Nossa Abordagem



EDA


- A análise exploratória de dados (EDA) é usada por cientistas de dados para analisar e investigar conjuntos de dados e resumir suas características principais, muitas vezes empregando métodos de visualização de dados.
- Ajuda a determinar a melhor maneira de manipular as fontes de dados para obter as respostas de que você precisa, tornando mais fácil para os cientistas de dados descobrir padrões, detectar anomalias, testar uma hipótese ou verificar suposições.

*Obtido do Site da IMB


EDA

- Conciliar análise estatística com visualização de dados é fundamental nessa fase.
- Ferramentas que tenham essas duas funcionalidades são muito úteis

Pacote Seaborn do Python




- o pacote **Seaborn** é de grande utilidade na etapa de Análise Exploratória de Dados (EDA - Exploratory Data Analysis), uma vez que se pode gerar várias análises estatísticas de forma gráfica sem se ater nos algoritmos estatísticos propriamente.



Pacote Seaborn do Python






- O pacote **Seaborn** fornece uma API no topo do Matplotlib.
- É integrado às funcionalidades dos DataFrames Pandas.
- Possui funções de alto nível para traçado de gráficos , utilizando implicitamente modelos estatísticos.



Pacote Seaborn do Python

- Estilo Seaborn

```
# Importação e configuração para o padrão Seaborn
import seaborn as sns
sns.set()
```



Pacote Seaborn do Python


- Estilo Seaborn

```
# Mesmo programa do exemplo anterior, porém com Seaborn
print("São os mesmos gráficos do exemplo anterior, mas num estilo de cores do Seaborn\n")
plt.plot(x, y)
plt.legend('ABCDEF', ncol=2, loc='upper left');
```

São os mesmos gráficos do exemplo anterior, mas num estilo de cores do Seaborn




```
# Plot dos dados com o pacote Matplotlib
plt.plot(x, y)
plt.legend('ABCDEF', ncol=2, loc='upper left');
```



Pacote Seaborn do Python

- Gráficos Estatísticos

Gráfico do tipo Box-Plot



Pacote Seaborn do Python

- Exemplos de gráficos com modelos estatísticos incorporados

```
plt.figure(figsize=(12, 7))  
sns.boxplot(x='ensino_fundamental_conclusao', y='ano_nascimento', data=dados, palette='winter')
```

<matplotlib.axes._subplots.AxesSubplot at 0x7f53dd026828>





Gráfico do tipo Box-Plot


Pacote Seaborn do Python

- Gráficos Estatísticos

Gráfico do tipo Box-Plot




Limitação do Box-Plot



Pacote Seaborn do Python

- Exemplos de gráficos com modelos estatísticos incorporados

```
sns.violinplot(data=df, y="DRG Definition",  
               x="Average Covered Charges")
```



```
sns.lvplot(data=df, y="DRG Definition",  
            x="Average Covered Charges")
```




Gráfico do tipo Violino – Box-Plot + FDP


Pacote Seaborn do Python

- Exemplos de gráficos com modelos estatísticos incorporados

```
# Suavização de curva com Seaborn
# Usando estimação de densidade de kernel - kernel density estimation (KDE)

print("KDE é uma técnica de interpolação de curvas \n- a partir de histogramas (que são discretos) se obtém curvas de
for col in 'xy':
    sns.kdeplot(data[col], shade=True)
```

KDE é uma técnica de interpolação de curvas
- a partir de histogramas (que são discretos) se obtém curvas de densidades de probabilidades (FDP) contínuas.



Exemplo de uso do método KDE
para obtenção de PDF

Métodos de Estimação de Densidades

- KDE (Kernel Density Estimation)
 - É basicamente um problema de suavização de histograma de um conjunto de dados finitos de uma determinada VA.
 - São técnicas não-paramétricas para se estimar a PDF de uma VA.
 - Estima a forma da FDP.
 - Utiliza-se a composição de n instâncias de uma função base (kernel)

Métodos de Estimação de Densidades

○ KDE (Kernel Density Estimation)

- Seja $(x_1, x_2, \dots, x_n)$ uma amostra iid obtida de uma **fdp $f(x)$** desconhecida.
 - O **estimador de densidade de kernel** é dado por:

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$


- Onde, $K(\cdot)$ é o kernel e é uma função simétrica.
- $h > 0$ é a largura de banda.
- Kernel de índice h é definido como: $K_h(x) = 1/h K(x/h)$

Métodos de Estimação de Densidades


○ KDE (Kernel Density Estimation)

- O estimador de densidade de kernel é dado por:

$$\hat{f}_h(x) = \frac{1}{n} \sum_{i=1}^n K_h(x - x_i) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - x_i}{h}\right),$$



Kernel density estimation of 100 normally distributed random numbers using different smoothing bandwidths.



Kernel density estimate (KDE) with different bandwidths of a random sample of 100 points from a standard normal distribution. Grey: true density (standard normal). Red: KDE with $h=0.05$. Black: KDE with $h=0.337$. Green: KDE with $h=2$.


Métodos de Estimação de Densidades

○ KDE (Kernel Density Estimation)

○ Exemplo: Histograma e KDE

- Histograma com 6 bins de largura 2
- KDE com kernel Normal com variância de 2.25.
 - São geradas 6 Gaussianas centralizadas nos respectivos 6 valores dados. O resultado é a soma das gaussianas (kernels)


Sample	1	2	3	4	5	6
Value	-2.1	-1.3	-0.4	1.9	5.1	6.2



Pacote Seaborn do Python

- Exemplos de gráficos com modelos estatísticos incorporados

```
# Combinando histograma com KDE  
sns.distplot(data['x'])  
sns.distplot(data['y']);
```



Combinado histograma e PDF

Descontinuado. Agora se utiliza :


```
sns.displot(data['x'])  
sns.displot(data['y'])
```

Pacote Seaborn do Python

- Exemplos de gráficos com modelos estatísticos incorporados

```
# Traçando duas curvas de níveis obtidas via KDE num mesmo gráfico
sns.kdeplot(iris_setosa['sepal_length'],
            iris_setosa['sepal_width'],
            color='r', shade=True, Label='Iris_Setosa',
            cmap="Reds", shade_lowest=False)

sns.kdeplot(iris_virginica['sepal_length'],
            iris_virginica['sepal_width'], color='b',
            shade=True, Label='Iris_Virginica',
            cmap="Blues", shade_lowest=False)
```




Curvas de nível com método KDE
Para o dataset Iris


Pacote Seaborn do Python

- Exemplos de gráficos com modelos estatísticos incorporados


```
sns.regplot(data=df, x='temp', y='total_rentals', marker='+')
```



```
sns.regplot(data=df, x='temp', y='total_rentals', order=2)
```



```
sns.regplot(data=df, x='mnth', y='total_rentals',  
            x_estimator=np.mean, order=2)
```




Utilizando métodos de regressão
linear e não linear de dados


Pacote Seaborn do Python – Gráfico heatmap

- Exemplos de gráficos com modelos estatísticos incorporados

```
sns.heatmap(df.corr())
```



```
sns.heatmap(df_crosstab, annot=True, fmt="d",  
             cmap="YlGnBu", cbar=False, linewidths=.5)
```



Utilizando métodos de visualização com matrizes


Pacote Seaborn do Python – Gráfico Pairplot

- Exemplos de gráficos com modelos estatísticos incorporados

```
# Para visualizar as relações multidimensionais entre as amostras  
# aos pares basta utilizar o método sns.pairplot()
```

```
sns.pairplot(iris, hue='species', size=2.5);
```


Utilizando método pairplot de visualização – matriz de correlação + FDP marginais + Scatter plot



Gráficos de Facetas

```
# Exemplo com o dataset 'tips'  
tips = sns.load_dataset('tips')  
tips.head()
```

	total_bill	tip	sex	smoker	day	time	size
0	16.99	1.01	Female	No	Sun	Dinner	2
1	10.34	1.66	Male	No	Sun	Dinner	3
2	21.01	3.50	Male	No	Sun	Dinner	3
3	23.68	3.31	Male	No	Sun	Dinner	2
4	24.59	3.61	Female	No	Sun	Dinner	4






```
tips['tip_pct'] = 100 * tips['tip'] / tips['total_bill']
```

```
grid = sns.FacetGrid(tips, row="sex", col="time", margin_titles=True)  
grid.map(plt.hist, "tip_pct", bins=np.linspace(0, 40, 15));
```

Pacote Seaborn do Python – Gráfico Q-Q

- Exemplos de gráficos com modelos estatísticos incorporados



Utilizando método Q-Q para visualizar o quanto uma distribuição (eixo Y) se aproxima de outra (Normal. Por exemplo – eixo X). Utiliza o número de quantil de X pelo do quantil de Y



"That's all Folks!"